GINWA FAKIH

Data Scientist — Systèmes physiques, modélisation de données & apprentissage automatique

ghinwafkh99@gmail.com • +33 6 26 63 68 73 • Nantes — France entière • linkedin.com/in/ghenwa-fkh

PROFIL

Data Scientist titulaire d'un doctorat en informatique, spécialisée en Intelligence Artificielle, Machine Learning et Data Science, avec une formation initiale en génie électrique et électronique. Expertise en analyse de données, NLP, graphes de connaissances, ontologies et développement de solutions data-driven avec Python, SQL et technologies du Web sémantique. Ce double parcours, bases en systèmes électriques et électrotechniques d'une part, modélisation avancée de données et apprentissage automatique d'autre part, me permet d'aborder l'analyse de données issues de machines industrielles avec à la fois une intuition physique et une rigueur méthodologique de recherche. Expérience dans la conception de modèles prédictifs, l'exploitation de données complexes et la valorisation de données à grande échelle, validée par des protocoles d'évaluation quantitatifs stricts.

COMPÉTENCES PERTINENTES POUR LE POSTE

- **Systèmes physiques & électrotechnique :** formation initiale en génie électrique et électronique (machines électriques, systèmes triphasés, signaux)
- **Apprentissage automatique :** Scikit-learn, TensorFlow, PyTorch, K-Means, arbres de décision, NLTK, spaCy, embeddings, clustering, classification
- **IA générative & LLM :** RAG (Retrieval-Augmented Generation), LangChain, OpenAI API, modèles Llama, embeddings vectoriels, FAISS
- **Langages de programmation :** Python (Pandas, Jupyter, Scikit-learn), Java, C/C++, SQL, SPARQL, TypeScript, HTML
- **Technologies des données & Web sémantique :** Apache Jena, RDF/OWL, SPARQL, Virtuoso, Linked Data, PostgreSQL, MySQL
- **Analyse de données & validation d'hypothèses :** conception de protocoles d'évaluation quantitatifs, formulation et test d'hypothèses, démarche scientifique rigoureuse
- **Visualisation de données :** Matplotlib, Seaborn, Plotly
- **Informatique en cloud et DevOps :** GCP, Docker, Windows, Linux
- **Compétences transversales :** Communication, résolution de problèmes, travail en équipe, gestion du temps, anglais courant

EXPÉRIENCE DE RECHERCHE

Doctorante — Graphes de connaissances et recherche sémantique | LS2N, Nantes / *02/2023 – 09/2025*

- Développé des solutions d'analyse et d'exploitation de données à grande échelle basées sur les graphes de connaissances, les ontologies et le Machine Learning.
- Conçu des schémas de métadonnées, ontologies et graphes de connaissances pour améliorer la qualité, l'interopérabilité et la gouvernance des données — compétence utile à la construction de datasets robustes pour l'entraînement de modèles.
- Conçu et implémenté des algorithmes de recherche, de classement et de recommandation utilisant des techniques de similarité sémantique et des embeddings de graphes — logique directement transposable à l'identification de signatures et d'anomalies dans des signaux industriels.
- Développé des pipelines de traitement de données et d'évaluation pour l'analyse de données graphique, avec formulation et test systématique d'hypothèses pour valider la pertinence des modèles produits face à des données incomplètes ou bruitées.
- Publications : Semantic Web Journal et SEMANTiCS (nomination Best Student Paper).

Stagiaire en recherche — Traitement automatique du langage | LS2N, Nantes / *02/2021 – 07/2021*

- Extraction et analyse de termes à partir de corpus textuels pour l'identification de thématiques métier.
- Développement et application d'un modèle probabiliste semi-supervisé (SeededLDA) pour la découverte et la classification de sujets.
- Construction, optimisation et consolidation de clusters thématiques par détection des recouvrements et élimination des redondances — méthodologie de détection de motifs directement applicable à l'identification de défauts machines.

PROJETS PERSONNELS

Research Paper Chatbot — Assistant documentaire basé sur le RAG | Projet personnel / *2026*

- Développé un chatbot permettant d'interroger des articles scientifiques en langage naturel et d'obtenir des réponses ancrées dans les documents sources, en combinant recherche documentaire et génération par LLM (Retrieval-Augmented Generation) afin de réduire les hallucinations.
- Implémenté le pipeline complet : extraction de texte PDF, découpage en chunks, génération d'embeddings (Sentence Transformers), indexation dans une base vectorielle FAISS, récupération contextuelle et génération de réponses via OpenAI API / modèles Llama, orchestrés avec LangChain.
- Ajouté la traçabilité des sources pour permettre la vérification des réponses, et déployé une interface interactive multi-documents avec Streamlit.
- *github.com/GhinwaFAKIH/Research-Paper-Chatbot-RAG-*

CV Job Matcher — Analyse explicable CV/offre d'emploi par LLM | Projet personnel / *2026*

- Conception d'une application combinant extraction d'information structurée par LLM et matching sémantique pour comparer un CV à une offre d'emploi, au-delà d'une simple analyse par mots-clés de type ATS.
- Architecture du pipeline : extraction de texte PDF, extraction structurée du profil candidat et des exigences du poste par LLM, moteur de matching produisant un score et des recommandations d'amélioration du CV fondées sur des preuves (evidence-based).
- *github.com/GhinwaFAKIH/cv-job-matcher*

EXPÉRIENCE PÉDAGOGIQUE

Attachée Temporaire d'Enseignement et de Recherche (ATER) | Nantes Université / *09/2024 – Présent*

- Enseignement en génie logiciel, algorithmique, bases de données et systèmes d'exploitation.
- Conception de TP sur l'optimisation SQL et le traitement des données.

FORMATION

Doctorat en Informatique — Nantes Université (2022–2025)
Modélisation et interrogation de données complexes à grande échelle. Thèse : « Relaxation of SPARQL queries in the presence of RDF reification », soutenue le 12/09/2025.

Master 2 en Data Science — Polytech Nantes (2020–2021)
Extraction de motifs textuels et séquentiels, clustering, classification, modèles graphiques probabilistes, analyse visuelle.

Licence en génie électrique et électronique, informatique et télécommunications — Université Libanaise, Beyrouth (2016–2020)
Fondamentaux en systèmes électriques, électronique et télécommunications — base technique directement pertinente pour l'analyse de machines tournantes triphasées.

PUBLICATIONS PRINCIPALES

- Fakih, G., Serrano-Alvarado, P., Perrin, M. (2025). SHARP: A Hybrid Approach for SPARQL Query Relaxation. 21st International Conference on Semantic Systems (SEMANTiCS), Vienna. Nominée Best Student Paper – R&I track.
- Fakih, G., Serrano-Alvarado, P. (2024). A survey on SPARQL query relaxation under the lens of RDF reification. Semantic Web, 15(6), 2507-2554.
- Kieffer, M., Fakih, G., Serrano-Alvarado, P. (2023). Evaluating Reification with Multi-valued Properties in a Knowledge Graph of Licensed Educational Resources. 19th International Conference on Semantic Systems (SEMANTiCS), Leipzig.

CERTIFICATIONS & LANGUES

Certifications : Managing Machine Learning Projects with Google Cloud (Coursera).

Langues : Arabe (langue maternelle) • Anglais (courant) • Français (B2, intermédiaire).